

# Taller Preparatorio Parcial #1

Hernan Supelano

Daniel Felipe Cendales

## Estimación histograma

Antes, cargamos las librerías necesarias

```
library(sm)
```

```
## Package 'sm', version 2.2-5.7: type help(sm) for summary information
```

1. Realizamos una simulación de tamaño 100 de  $X \sim \mathcal{N}(\mu = 17, \sigma^2 = 4)$

```
## Ajustamos los parámetros iniciales
n <- 100                                # Tamaño de la muestra
mu <- 20                                # Media teórica
sigma <- 2                               # Desv. estándar teórica
set.seed(n)                             # Fijamos la semilla

# Tomamos la muestra
datos <- rnorm(n = n, mean = mu, sd = sigma) #  $X \sim N(20, 4)$ 

## Estimación histograma
histograma <- hist(datos, plot = FALSE)
```

- a. Notemos que:

```
# Extraemos la estimación histograma de la densidad
densidad1 <- histograma$density

# Extraemos los conteos y los extremos de un intervalo
ni <- histograma$counts                # Conteos en cada intervalo
cortes <- histograma$breaks[1:2]       # Los dos primeros puntos
b <- diff(cortes)/2                     # Distancia sobre 2
densidad2 <- ni / (2*n*b)              # Calculamos la densidad

# Comparamos los vectores
all.equal(densidad1, densidad2)        # Hacemos la comparación
```

```
## [1] TRUE
```

- b. Sea  $x$  el punto medio de un intervalo. Vamos a plantar dos casos:

- **Caso 1:** la distancia del punto medio de un intervalo a uno de los extremos es  $b$ , lo que implica que la

longitud de los intervalos es de  $2b$ . Entonces

$$\begin{aligned}
 n_j &= \#\{x_i : x - b \leq x_i \leq x + b\} \\
 &= \#\{x_i : -b \leq x_i - x \leq b\} \\
 &= \#\left\{x_i : -1 \leq \frac{x_i - x}{b} \leq 1\right\} \\
 &= \sum_{i=1}^n I_{[-1,1]} \left( \frac{x_i - x}{b} \right)
 \end{aligned}$$

Y por ende la estimación histograma toma la forma:

$$\begin{aligned}
 \widehat{f_H}(x) &= \frac{n_j}{2bn} \\
 &= \frac{1}{2bn} \sum_{i=1}^n I_{[-1,1]} \left( \frac{x_i - x}{b} \right) \\
 &= \frac{1}{nb} \sum_{i=1}^n \frac{1}{2} I_{[-1,1]} \left( \frac{x_i - x}{b} \right)
 \end{aligned}$$

- **Caso 2:** la longitud del intervalo es  $b$ . Es decir que la distancia del punto medio a uno de los extremos es  $b/2$ . Entonces

$$\begin{aligned}
 n_j &= \#\left\{x_i : x - \frac{b}{2} \leq x_i \leq x + \frac{b}{2}\right\} \\
 &= \#\left\{x_i : -\frac{b}{2} \leq x_i - x \leq \frac{b}{2}\right\} \\
 &= \#\left\{x_i : -\frac{1}{2} \leq \frac{x_i - x}{b} \leq \frac{1}{2}\right\} \\
 &= \sum_{i=1}^n I_{[-\frac{1}{2}, \frac{1}{2}]} \left( \frac{x_i - x}{b} \right)
 \end{aligned}$$

Y por ende la estimación histograma toma la forma:

$$\begin{aligned}
 \widehat{f_H}(x) &= \frac{n_j}{bn} \\
 &= \frac{1}{bn} \sum_{i=1}^n I_{[-\frac{1}{2}, \frac{1}{2}]} \left( \frac{x_i - x}{b} \right)
 \end{aligned}$$

c. Gráfico de curvas teóricas y sus estimaciones.

Primero debemos calcular el  $b$  óptimo. Para ello, recordemos la fórmula (asumimos normalidad sobre  $f$ )

$$b = 3.491 \cdot \hat{\sigma} \cdot n^{-1/3}$$

donde  $\hat{\sigma} = \frac{\text{RIC}}{1.35}$

Pero el  $b$  óptimo necesita de  $\sigma$  y no de  $\hat{\sigma}$ . Entonces lo primero que hacemos será realizar varias simulaciones para encontrar el valor óptimo.

Calculemos entonces las cantidades necesarias:

```

# Inicio de las simulaciones
N <- 500 # Cantidad de simulaciones
muestras <- matrix(0, nrow = n, ncol = N) # Guardamos 500 muestras de tamaño 100
b0s <- NULL # Almacenamos los b's

for(i in 1:N)
{
  muestras[, i] <- rnorm(n, mean = mu, sd = sigma) # Toma de la muestra
  cuartiles <- quantile(muestras[, i], # Primer y tercer cuartil
                        probs = c(1, 3)/4, names = FALSE)
  RICs <- diff(cuartiles) # Rango intercuartílico
  sigmas_hat <- min(RICs / 1.35, sd(muestras[, i]))
  b0s[i] <- 3.491 * sigmas_hat * n^(-1/3) # b'óptimo de cada muestra
}

# Cálculo del b óptimo como promedio de todos los b's
( b_Optimo <- mean(b0s) )

```

```
## [1] 1.436161
```

```

# b óptimo obtenido de la muestra
RIC_datos <- diff(quantile(datos, probs = c(1, 3)/4, names = FALSE))
sigma_hat <- min(RIC_datos / 1.35, sd(datos))
3.491 * sigma_hat * n^(-1/3)

```

```
## [1] 1.409223
```

Ya calculado el  $b$  óptimo, podemos hacer la gráfica de la densidad teórica y la estimación que obtuvimos

```

# A 5 desviaciones estándar (de la media), en una normal, estará el 99%
lLmites <- mu + c(-1, 1) * 5 * sigma

# Extremos de los intervalos
puntos <- seq(from = lLmites[1], to = lLmites[2] + 1, by = b_Optimo)

# Histograma con el ancho de banda óptimo
Hist <- hist(datos, breaks = puntos, plot = FALSE)


# Curva teórica
rango <- seq(from = lLmites[1], to = lLmites[2], by = 0.1)
plot(x = rango, y = dnorm(rango, mu, sigma), frame = FALSE,
     xlab = "X", ylab = "Densidad", type = "l", las = 1,
     lwd = 2, ylim = c(0, max(Hist$density)), col = "blue",
     main = bquote("Estimación histograma, b" == .(round(b_Optimo, 3))))

# Gráfico del histograma
lines(x = puntos, y = c(Hist$density, 0), type = "s")

# Leyenda
legend(x = "topright", lwd = 2:1, col = c("blue", "black"),
       legend = c("Teórica", "Histograma"), bty = "n")

```

## Estimación histograma, $b = 1.436$



Para agregar la curva de  $E\{\widehat{f}_H(x)\}$  vamos a usar la muestras generadas, calculamos el promedio y las varianzas

```
# Obtenemos los histogramas de cada muestra
histogramas <- apply(muestras, 2, function(k){
  c(hist(k, breaks = puntos, plot = FALSE)$density, 0)
})

E_fh <- apply(histogramas, 1, mean)          # Valor esperado
Sd_fh <- apply(histogramas, 1, sd)          # Desviación estándar


plot(x = rango, y = dnorm(rango, mu, sigma), frame = FALSE,
     xlab = "X", ylab = "Densidad", type = "l", las = 1,
     lwd = 2, ylim = c(0, max(Hist$density)), col = "blue",
     main = bquote("Estimación histograma, b" == .(round(b_Optimo, 3))))

# Gráfico del histograma
lines(x = puntos, y = c(Hist$density, 0), type = "s", lty = 2)

# Esperanza
lines(x = puntos, y = E_fh, col = "brown", lwd = 2, type = "l")

# Leyenda
legend(x = "topright", lwd = c(2, 1, 2), col = c("blue", "black", "brown"),
      legend = c("Teórica", "Histograma", "Esperanza"), bty = "n",
      lty = c(1, 2, 1))
```

## Estimación histograma, $b = 1.436$



Para intentar ver el comportamiento de la varianza, podemos graficar todos los histogramas obtenidos y después agregamos unas “bandas de confianza”

```
# Todos los histogramas obtenidos
matplot(x = puntos, y = histogramas, type = "s", las = 1,
        col = "gray", lty = 1, frame = FALSE, lwd = 0.5,
        xlab = "Observados", ylab = "Densidades",
        main = bquote("Histogramas, b" == .(round(b_Optimo, 3))))

# El histograma de la muestra inicial
lines(x = puntos, y = c(Hist$density, 0), col = "black",
      lwd = 2, type = "s", lty = 5)

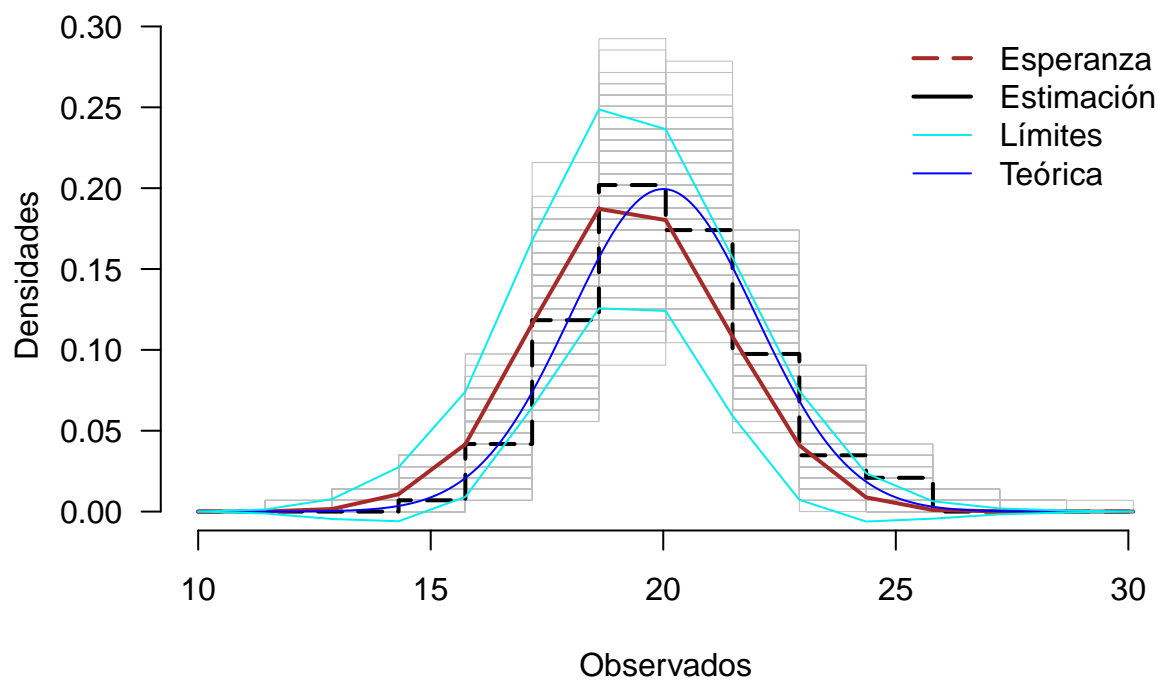
# Valor esperado
lines(x = puntos, y = E_fh, col = "brown", lwd = 2, type = "l")

# Estimación teórica
lines(rango, dnorm(rango, mean = mu, sd = sigma), col = "blue")

# "Bandas de confianza"
matlines(x = puntos, y = cbind(E_fh - 1.96 * Sd_fh,
                              E_fh + 1.96 * Sd_fh),
        type = "l", col = "cyan2", lty = 1, lwd = 1)

# Leyenda
legend(x = "topright", bty = "n", col = c("brown", "black", "cyan2", "blue"),
      lwd = rep(2:1, each = 2), lty = c(5, 1, 1, 1),
      legend = c("Esperanza", "Estimación", "Límites", "Teórica"))
```

## Histogramas, b = 1.436



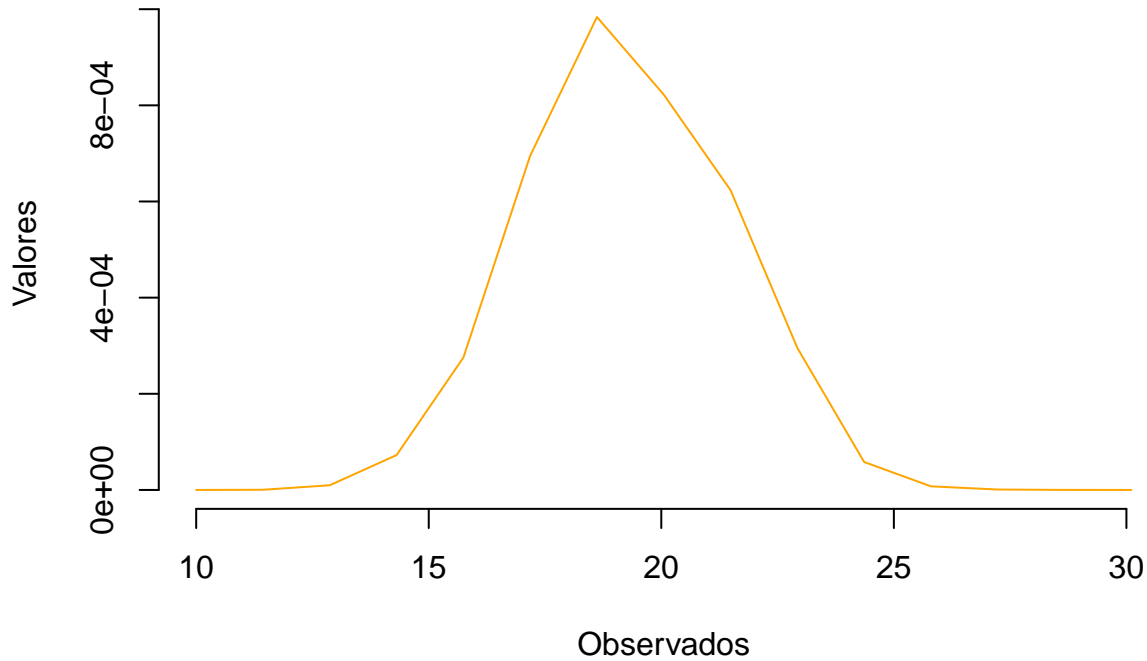
d. Gráfico de la curva  $V \left\{ \widehat{f}_H(x) \right\}$

El gráfico anterior sugería que en los extremos la varianza disminuye y en la parte central es donde más alta es esta. Veamos gráficamente que esto es así:

*# Gráfico de la varianza*

```
plot(x = puntos, y = Sd_fh^2, main = "Gráfico de la varianza", frame = FALSE,
     xlab = "Observados", ylab = "Valores", type = "l", col = "orange")
```

## Gráfico de la varianza



## Estimación Kernel de la densidad

a. Tomando los datos del inicio, realizamos el cálculo del  $h$  de Silverman

```
h_Silverman <- 0.9 * sigma_hat * n^(-1/5)
```

El valor de este ancho de banda es aproximadamente 0.671

b. Si asumimos un Kernel Gaussiano, la fórmula del  $MISE$  viene dada por:

$$MISE(\hat{f}_k) = \frac{R(K)}{nh} + \frac{\sigma_k^4 h^4}{4} R(f'') + O\left(\frac{1}{n}\right) + O(h^5)$$

Como estamos usando un kernel gaussiano con  $\sigma^2 = 1$ , entonces  $R(K) = \frac{1}{2\sqrt{\pi}\sigma_k}$  y  $R(f'') = \frac{3}{8\sigma^5\sqrt{\pi}}$  ya que muestreamos de una distribución normal.

$$MISE(\hat{f}_k) = \frac{1}{2nh\sigma_k\sqrt{\pi}} + \frac{3\sigma_k^4 h^4}{32\sigma^5\sqrt{\pi}} + O\left(\frac{1}{n}\right) + O(h^5)$$

Haciendo uso del  $h$  de Silverman obtenemos un valor para el  $AMISE$  de

```
( MISE <- 1/(2*n*h_Silverman*sqrt(pi)) + 3*h_Silverman^4/(32*sd(datos)^5*sqrt(pi)) )
```

```
## [1] 0.004505032
```

c. Primero necesitamos estimar la densidad para los datos simulados

```
# Estimamos la densidad de los datos originales
densidad_hSilver <- density(datos, bw = h_Silverman, kernel = "gaussian",
                             n = 512, from = min(datos), to = max(datos))
```

```
f_x1 <- densidad_hSilver$y[1]
```

Entonces, la estimación en el mínimo de la muestra es  $\hat{f}_k(x_{(1)}) = 0.0265689$ .

Recordando el intervalo desarrollado con el método delta, tenemos que un intervalo de confianza para  $f(x)$  (considerando el sesgo despreciable, i.e.  $E(\hat{f}_K(x_{(1)})) = f(x_{(1)})$ )

$$IC = \left[ \sqrt{\hat{f}_k(x_{(1)})} \pm Z_{1-\frac{\alpha}{2}} \sqrt{\frac{R(K)}{4nh}} \right]^2$$

Entonces, el intervalo de confianza viene dado por:

```
# Construimos el intervalo con alpha = 0.05
alpha <- 0.05 # Nivel de significancia
z_c <- qnorm(1 - alpha/2) # Cuantil de la normal

R_k <- (2*sqrt(pi))^-1

(sqrt(f_x1) + c(-1, 1) * z_c * sqrt(R_k/(4*n*h_Silverman)))^2

## [1] 0.009895201 0.051313586
```

d. Primero calculemos las cantidades necesarias. Entonces

```
# La desviación estándar ya la habíamos calculado con anterioridad
mu_est <- mean(datos) # Media estimada
h_normal <- 1.059 * sigma_hat * n^-1/5 # h estimado
```

Por ende tenemos que:

- El valor de  $h = 0.7899$
- El valor de  $\hat{\mu} = 20.006$
- El valor de  $\hat{\sigma} = 2.041$

Como cambiamos el  $h$ , debemos re calcular la estimación kernel

```
# Estimación kernel con el h de referencia Normal
densidad_hNormal <- density(datos, bw = h_normal, kernel = "gaussian",
                             n = 512, from = min(datos), to = max(datos))

f_xn <- densidad_hNormal$y[512] # Estimación de E[f(xn)]
V_fxn <- (dnorm(0, 0, sd = sqrt(2*h_normal^2)) *
          dnorm(max(datos), mu_est,
                 sd = sqrt(sd(datos)^2 + h_normal^2/2)) -
          dnorm(max(datos), mu_est,
                 sd = sqrt(sd(datos)^2 + h_normal^2))^2)/n
```

Por ende tenemos que:

- El valor de  $\hat{E}[\hat{f}_K(x_{(n)})] = 0.0174$
- El valor de  $V[\hat{f}_K(x_{(n)})] = 3.3 \times 10^{-5}$
- Las bandas de referencia a la normal son



```
f_xn + c(-1, 1) * 2.575 * sqrt(V_fxn)
```

```
## [1] 0.002509719 0.032207437
```

e. Bandas de variabilidad de  $E \left[ \hat{f}_k(x) \right]$

```
# Bandas de referencia
x_obs <- densidad_hNormal$x
y_dens <- densidad_hNormal$y

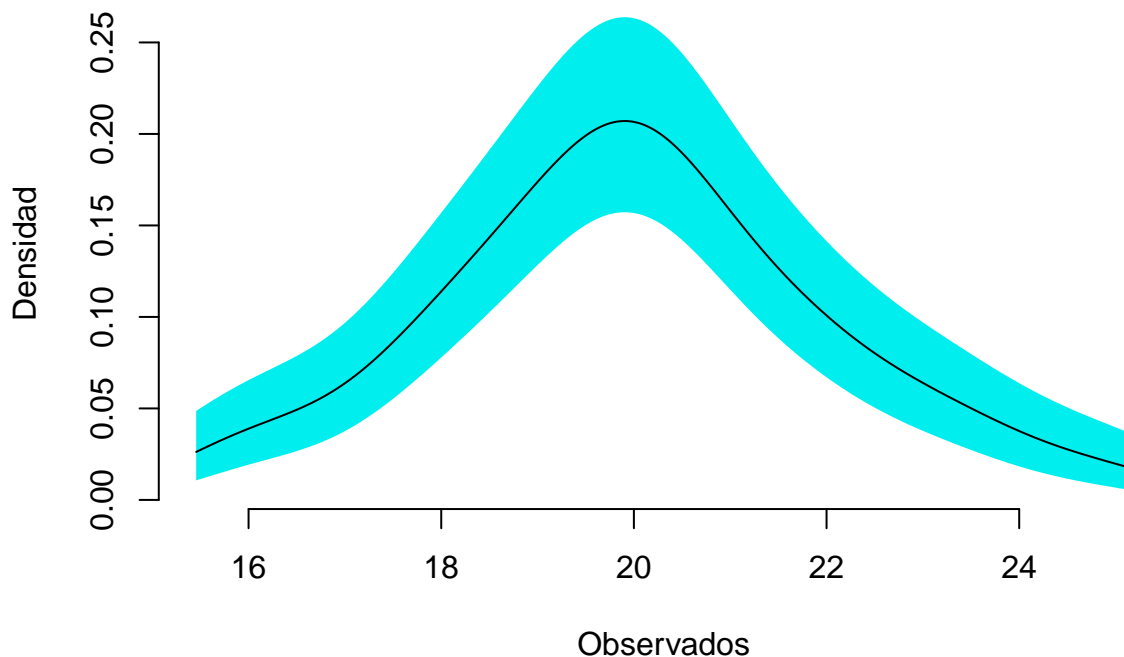
band_inf <- (sqrt(y_dens) - z_c * sqrt(R_k/(4*n*h_normal)))^2
band_sup <- (sqrt(y_dens) + z_c * sqrt(R_k/(4*n*h_normal)))^2

# Gráfico de la densidad
plot(x = x_obs, y = y_dens, type = "n", frame = FALSE,
     ylim = c(min(band_inf), max(band_sup)), lwd = 2,
     xlab = "Observados", ylab = "Densidad",
     main = "Estimación y bandas de confianza")

polygon(x = c(x_obs, x_obs[512:1]), border = NA,
       y = c(band_inf, band_sup[512:1]), col = "cyan2")

lines(x = x_obs, y = y_dens)
```

## Estimación y bandas de confianza



```
# Agregamos las líneas de la densidad
# matlines(x = x_obs, y = cbind(band_inf, band_sup), col = "cyan2",
#         lwd = 2, lty = 1)
```

f. Bandas de referencia a la normal

```

# Bandas de referencia a la normal
E_fx <- dnorm(x_obs, mean = mu_est,
             sd = sqrt(var(datos) + h_normal^2))
V_fx <- (dnorm(0, 0, sd = sqrt(2*h_normal^2)) *
        dnorm(x_obs, mean = mu_est,
             sd = sqrt(var(datos) + h_normal^2/2)) -
        dnorm(x_obs, mean = mu_est,
             sd = sqrt(var(datos) + h_normal^2))^2)/n

band_infN <- E_fx - qnorm(0.975)*sqrt(V_fx)
band_supN <- E_fx + qnorm(0.975)*sqrt(V_fx)


# Gráfico de la densidad
plot(x = x_obs, y = y_dens, type = "n", frame = FALSE,
     ylim = c(min(band_inf), max(band_sup)), lwd = 2,
     xlab = "Observados", ylab = "Densidad",
     main = "Bandas de confianza\nreferencia a la Normal")

polygon(x = c(x_obs, x_obs[512:1]), border = NA,
       y = c(band_infN, band_supN[512:1]), col = "cyan2")

lines(x = x_obs, y = y_dens)

```

### Bandas de confianza referencia a la Normal



g. Test de normalidad usando *nise*

```

set.seed(7)           # Fijamos la semilla

T_obs <- nise(datos)   # T observado
num_sim <- 1000        # Número de simulaciones

```

```
T_simul <- replicate(num_sim, expr = nise(rnorm(n)))
( pval <- sum(T_simul > T_obs)/num_sim )
```

```
## [1] 0.409
```

```
# Graficamos la distribución asociada
```

```
densidad_t <- density(T_simul)
d_x <- densidad_t$x
d_y <- densidad_t$y
```


```
plot(d_x, d_y, frame = FALSE, type = "l",
     main = "Distribución aproximada de T",
     xlab = "T observados", ylab = "Densidad")
```

```
# Graficamos el valor-p
```

```
x_indice <- d_x[d_x > T_obs]
y_indice <- d_y[d_x > T_obs]
```

```
polygon(x = c(x_indice[1], x_indice), #border = "",
       y = c(0, y_indice), col = "gray")
```

## Distribución aproximada de T



h. Comparación de distribuciones:


- **Bajo igualdad de distribuciones:** vamos a usar variables de una variable aleatoria normal

```
# Fijamos la semilla
set.seed(31416)
```

```
X <- rnorm(200, mean = 23, sd = 7) # Hacemos la toma de las muestras
```

```
grupo <- rep(paste0("g", 1:2),      # Creamos los respectivos grupos
             each = 100)
sm.density.compare(x = X, group = grupo, model = "equal")
```

```
## Test of equal densities:  p-value = 0.24
```



Vemos


que no se rechaza la hipótesis nula de igualdad de distribuciones.

- **Bajo diferencia de distribuciones:** vamos a usar variables de una variable aleatoria normal

```
# Fijamos la semilla
set.seed(31416)

X <- c(rnorm(102, 17, 2), rnorm(98, 17, 3))
grupo <- rep(paste0("g", 1:2), c(102, 98))
sm.density.compare(x = X, group = grupo, model = "equal")
```

```
## Test of equal densities:  p-value = 0
```



podemos ver que rechazamos la hipótesis nula de igualdad de distribuciones.

i. Réplica de la función

```
# Gráfico de la distribución teórica
mu1 <- -1
mu2 <- 1
sd <- 0.3

x <- seq(-3, 3, by = 0.05)      # Rango de valores
y <- dnorm(x, mu1, sd = sd) +    # Parecen suma de normales :v
    dnorm(x, mu2, sd = sd)

set.seed(6)
x1 <- rnorm(5, mu1, sd = sd)
x2 <- rnorm(5, mu2, sd = sd)

plot(x, y, type = "l", main = "Figura 1", frame = FALSE)

X <- c(x1, x2)
# Agregamos los puntos de las simulaciones
points(x = X, y = rep(0, length(X)), pch = 19, cex = 0.5)


# Ancho de banda
bw <- 0.3
d_k <- sapply(X, function(k) dnorm(k-x, 0, sd = bw))

alturas <- apply(d_k, 2, max)
matlines(x = x, y = d_k/5, lty = 3, col = "gray0")

segments(x0 = X, y0 = rep(0, 10), x1 = X, y1 = alturas/5)
apply(d_k, 1, sum) / 5 -> estimaciOn

lines(x, estimaciOn, lty = 5, col = "gray0")
```

**Figura 1**



## 2. Demostración

$$\begin{aligned}
 E\{\widehat{f_H}(x)\} &= E\left\{\frac{1}{nb} \sum_{i=1}^n K_h\left(\frac{x - X_i}{b}\right)\right\} \\
 &= \frac{1}{nb} E\left\{\sum_{i=1}^n K_H\left(\frac{x - X_i}{b}\right)\right\} \\
 &\stackrel{\text{linealidad}}{=} \frac{1}{nb} \sum_{i=1}^n E\left\{K_H\left(\frac{x - X_i}{b}\right)\right\} \\
 &\stackrel{\text{iid}}{=} \frac{1}{b} E\left\{K_H\left(\frac{x - X}{b}\right)\right\} \stackrel{\text{simetría}}{=} \frac{1}{b} E\left\{K_H\left(\frac{X - x}{b}\right)\right\} \\
 &= \frac{1}{b} \int_{-\infty}^{\infty} K_H\left(\frac{s - x}{b}\right) f_X(s) ds \\
 &\stackrel{t = \frac{s - x}{b}}{=} \frac{1}{b} \int_{-\infty}^{\infty} K_H(t) f_X(x + tb) dt \\
 &\stackrel{\text{E. Taylor}}{=} \int_{-\infty}^{\infty} K_H(t) [f_X(x) + O(b)] dt \\
 &= [f_X(x) + O(b)] \int_{-\infty}^{\infty} K_H(t) dt \\
 &= f_X(x) + O(b)
 \end{aligned}$$

## 3. Demostración:

$$\begin{aligned}
V \{ \widehat{f_H}(x) \} &= V \left\{ \frac{1}{nb} \sum_{i=1}^n K_H \left( \frac{X_i - x}{b} \right) \right\} \\
&\stackrel{\text{reescalado}}{=} \frac{1}{n^2} V \left\{ \sum_{i=1}^n K_{H_b}(X_i - x) \right\} \\
&\stackrel{iid}{=} \frac{1}{n^2} \mathcal{H} V \{ K_{H_b}(X - x) \} \\
&= \frac{1}{n} E \{ K_{H_b}(X - x)^2 \} - \frac{1}{n} [E \{ K_{H_b}(X - x) \}]^2
\end{aligned}$$

Notemos que, como  $E \{ K_{H_b}(X - x) \}$  existe, implica que existe un  $c \in \mathbf{R}^+$  tal que  $|E \{ K_{H_b}(X - x) \}| \leq c \implies |E \{ K_{H_b}(X - x) \}|^2 \leq c^2$ .

Por ende podemos deducir que

$$\begin{aligned}
\frac{1}{n} |E \{ K_{H_b}(X - x) \}|^2 &\leq \frac{c^2}{n} \\
&\implies \frac{1}{n} |E \{ K_{H_b}(X - x) \}|^2 = O \left( \frac{1}{n} \right)
\end{aligned}$$

Nos falta analizar  $\frac{1}{n} E \{ K_{H_b}(X - x)^2 \}$ . Notemos que

$$\begin{aligned}
\frac{1}{n} E \{ K_{H_b}(X - x)^2 \} &= \frac{1}{n} E \left\{ \frac{1}{b^2} K_H \left( \frac{X - x}{b} \right)^2 \right\} = \frac{1}{nb^2} E \left\{ K_H \left( \frac{X - x}{b} \right)^2 \right\} \\
&= \frac{1}{nb^2} \int_{-\infty}^{\infty} K_H \left( \frac{s - x}{b} \right)^2 f_X(s) ds \\
&\stackrel{t = \frac{s-x}{b}}{=} \frac{1}{nb^2} \int_{-\infty}^{\infty} K_H(t)^2 f_X(x + tb) b dt \\
&= \frac{1}{nb} \int_{-\infty}^{\infty} K_H(t)^2 [f_X(x) + O(b)] dt \\
&= [f_X(x) + O(b)] \frac{1}{nb} \int_{-\infty}^{\infty} K_H(t)^2 dt \\
&= \frac{1}{nb} [f_X(x) + O(b)] R(K) \\
&= \frac{f_X(x)R(K)}{nb} + \frac{R(K)}{nb} O(b) = \frac{f_X(x)R(K)}{nb} + \frac{1}{nb} O(b)
\end{aligned}$$

El término  $O(b)$  expresa que la función original está acotada por la función  $kb$  para algún  $k \in R$ . Luego  $\frac{O(b)}{b}$  estará acotado por una constante. Lo que nos lleva a deducir que  $\frac{O(b)}{nb}$  está acotado por una múltiplo de  $\frac{1}{n}$ . Es decir, que  $\frac{O(b)}{nb} = O \left( \frac{1}{n} \right)$ . Resumiendo lo anterior, tenemos que

$$\frac{1}{n} E \{ K_{H_b}(X - x)^2 \} = \frac{f_X(x)R(K)}{nb} + O \left( \frac{1}{n} \right)$$

Que a su vez implica que

$$V \left\{ \widehat{f_H}(x) \right\} = \frac{f_X(x)R(K)}{nb} + O\left(\frac{1}{n}\right) - O\left(\frac{1}{n}\right)$$

La expresión  $O\left(\frac{1}{n}\right) - O\left(\frac{1}{n}\right)$  es una combinación lineal de múltiplos de funciones de la forma  $\frac{1}{n}$  y por ende dicha combinación será acotada por una función de la forma  $\frac{1}{n}$ . Es decir que  $O\left(\frac{1}{n}\right) - O\left(\frac{1}{n}\right) = O\left(\frac{1}{n}\right)$ . Lo que nos permite completar nuestra demostración, i.e.

$$V \left\{ \widehat{f_H}(x) \right\} = \frac{f_X(x)R(K)}{nb} + O\left(\frac{1}{n}\right)$$

4. **Demostración:** sea  $X \sim \mathcal{N}(\mu, \sigma^2)$ . Tenemos que la función de densidad de  $X$  viene dada por:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\}$$

La derivada de esta función viene dada por:

$$\begin{aligned} \frac{d}{dx} f_X(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} \left( -\frac{2(x-\mu)}{2\sigma^2} \right) \\ &= -\frac{(x-\mu)}{\frac{\sqrt{2}}{2}\sigma \cdot \sigma} f_X(x) = -\frac{1}{\sqrt{2}\sigma} \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} f_X(x) \end{aligned}$$

Y al elevar el cuadrado la expresión anterior se sigue que

$$\begin{aligned} \left[ f'_X(x) \right]^2 &= \frac{1}{2\sigma^2} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 f_X(x)^2 \\ &= \frac{1}{2\sigma^2} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 \frac{1}{\sqrt{2\pi\sigma^2}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{2(x-\mu)^2}{2\sigma^2} \right\} \\ &= \frac{1}{2\sigma^2 \sqrt{2\pi\sigma^2}} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 \frac{1}{\sqrt{2\pi 2\frac{\sigma^2}{2}}} \exp \left\{ -\frac{(x-\mu)^2}{2\frac{\sigma^2}{2}} \right\} \\ &= \frac{1}{2\sigma^2 \sqrt{2\pi\sigma^2} \sqrt{2}} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 f_{X^*}(x) \\ &= \frac{1}{4\sigma^2 \sqrt{\pi\sigma^2}} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 f_{X^*}(x) \end{aligned}$$

La función  $f_{X^*}(x)$  se puede entender como la función de densidad de una variable aleatoria normal con media  $\mu^* = \mu$  y varianza  $\sigma^{*2} = \frac{\sigma^2}{2}$ . Integrando sobre  $x$  la expresión anterior se tiene que

$$\begin{aligned} R(f') &= \int_{-\infty}^{\infty} \frac{1}{4\sigma^3 \sqrt{\pi}} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 f_{X^*}(x) dx \\ &= \frac{1}{4\sigma^3 \sqrt{\pi}} \int_{-\infty}^{\infty} \left( \frac{x-\mu}{\frac{\sigma}{\sqrt{2}}} \right)^2 f_{X^*}(x) dx \end{aligned}$$



La integral anterior vemos que expresa el cálculo de un valor esperado. Para ser más exactos, estamos calculando  $E \left[ \left( \frac{X^* - \mu^*}{\sigma^*} \right)^2 \right]$ . Pero esa transformación corresponde al valor esperado de una variable aleatoria *chi* cuadrado, con un grado de libertad. Como el valor esperado de esta corresponde a sus grados de libertad, se tiene que

$$R(f') = \frac{1}{4\sigma^3\sqrt{\pi}} E \left[ \left( \frac{X^* - \mu^*}{\sigma^*} \right)^2 \right] = \frac{1}{4\sigma^3\sqrt{\pi}}$$